PROFESSOR: Rodnil da Silva Moreira Lisboa	
CURSO: Ciência da Computação	
DISCIPLINA: Análise Inferencial de Dados	
TURMA: Noturno	**DATA:** 09/11
ALUNO(A): Enzo Henrique, Harry Zhu, Murilo Ângelo, Vitor Kolle	

1. Introdução

Este trabalho analisa os dados financeiros disponibilizados pela CTI, com o objetivo de compreender como a receita dos diferentes cenários evoluiu ao longo dos períodos observados. Entre as contas do balanço patrimonial (BAL), da demonstração do resultado do exercício (DRE) e do fluxo de caixa (FLU), foi escolhida a conta DRE - Receita, por permitir uma análise direta das variações nos valores registrados.

Além de descrever o comportamento dos dados, o estudo procura identificar se existe uma tendência de crescimento ou redução da receita e se essa tendência é estatisticamente significativa. Para isso, foram realizadas etapas de organização e tratamento da base, cálculos estatísticos por período, construção de gráficos e comparação entre modelos de regressão.

A análise considera duas hipóteses: a hipótese nula (H0), que estabelece a ausência de uma tendência média da receita ao longo do tempo, e a hipótese alternativa (H1), que considera a existência dessa tendência. Foi adotado um nível de significância de 5%, de modo que valores-p inferiores a 0,05 foram considerados evidências estatísticas suficientes para rejeitar H0.

A base de dados utilizada reúne informações de 12 períodos consecutivos, identificados do Ano 1 ao Ano 12.

2. Metodologia

O estudo foi desenvolvido no Google Colab, utilizando a linguagem Python e as bibliotecas pandas, NumPy, SciPy, Matplotlib e Seaborn. A metodologia envolveu a importação e limpeza dos dados, a verificação de sua estrutura, a análise exploratória da receita, a aplicação de modelos estatísticos e a avaliação dos resíduos e dos erros de previsão.

Como cada cenário apresenta registros em diferentes períodos, foi utilizado um modelo de regressão com efeitos fixos por cenário. Essa abordagem permite considerar as diferenças entre os cenários que permanecem constantes ao longo do tempo, concentrando a análise nas variações da receita dentro de cada um deles. Também foram adotados erros-padrão agrupados por cenário, considerando que observações de uma mesma unidade podem apresentar dependência entre períodos distintos.

Parte dos procedimentos estatísticos foi implementada diretamente com NumPy e SciPy, incluindo a centralização das variáveis em relação às médias de cada cenário e a realização de testes sobre os resíduos. Os valores monetários foram apresentados em bilhões, sem aplicação de correção inflacionária.

Para estimar o modelo de efeitos fixos, foi utilizada a transformação within, que consiste em subtrair de cada observação a média do cenário ao qual ela pertence. Dessa forma, é possível analisar especificamente as mudanças que ocorrem ao longo do tempo dentro dos cenários, sem que as diferenças constantes entre eles interfiram no ajuste.

3. Desenvolvimento e Resultados

3.1. Identificação da base de dados e configuração de preferências

Inicialmente, foram importadas as bibliotecas necessárias para a análise, definido o nível de significância de 5% e estabelecida uma semente aleatória para facilitar a reprodução dos resultados.

Como o arquivo CSV não possui cabeçalho e utiliza ponto e vírgula como separador, os dados foram inicialmente carregados como texto. Em seguida, os valores numéricos, originalmente registrados no formato brasileiro, foram convertidos para permitir seu processamento.

3.2. Tratamento e organização dos dados

Durante o pré-processamento, foram padronizados os nomes das contas, extraídos os identificadores numéricos dos períodos e convertidos os valores para o formato numérico. Também foram realizadas verificações para identificar possíveis dados ausentes e registros duplicados.

Na conta DRE - Receita, não foram encontrados valores ausentes, registros repetidos para uma mesma combinação de cenário e ano, nem receitas menores ou iguais a zero.

Após a seleção dessa conta, a base utilizada na análise ficou composta por 14.400 observações, distribuídas entre 1.200 cenários acompanhados durante 12 períodos.

3.3. Estrutura do painel de dados

A base apresenta um registro de receita para cada combinação de cenário e período, formando um painel balanceado de 12 anos. Como todas as combinações estão representadas, não foi necessário preencher valores ausentes ou criar observações artificiais.

Essa organização permite acompanhar a evolução da receita de cada cenário durante todo o intervalo analisado. Ainda assim, é importante considerar a possibilidade de existirem características compartilhadas entre diferentes unidades.

3.4. Análise exploratória por período

Para compreender o comportamento da receita ao longo do tempo, foram calculadas estatísticas descritivas para cada período, incluindo quantidade de observações, média, mediana, desvio-padrão, valores mínimo e máximo e coeficiente de assimetria.

Os gráficos mostraram uma tendência geral de crescimento da receita, embora esse avanço não tenha ocorrido com a mesma intensidade em todos os períodos. Também foram observados valores coincidentes em determinados cenários, o que exige cautela na interpretação, já que a documentação da base não esclarece se existe alguma relação entre essas unidades.

Em termos de valores, a receita média passou de aproximadamente 6,679 bilhões no Ano 1 para 11,962 bilhões no Ano 12. Vale destacar que esses valores são nominais e que o arquivo não informa explicitamente a moeda utilizada.

3.5. Regressão linear com efeitos fixos

O primeiro modelo analisado foi uma regressão linear que relaciona a receita ao período, considerando efeitos fixos para cada cenário.

O coeficiente associado ao tempo foi positivo e apresentou valor-p inferior a 0,05. Esse resultado permitiu rejeitar a hipótese nula (H0), indicando a existência de uma tendência média de crescimento da receita. No entanto, isso não significa que o crescimento tenha ocorrido de maneira uniforme ao longo dos períodos.

O coeficiente estimado foi de aproximadamente 0,4413 bilhão por período. Já o coeficiente de determinação interno, conhecido como R^2 within, foi de 0,840. Isso indica que o modelo linear consegue explicar uma parcela considerável das variações da receita ao longo do tempo dentro dos cenários, embora não represente toda a variação observada.

3.6. Qualidade do ajuste e previsão

Para avaliar a qualidade dos modelos, foram utilizados diferentes indicadores estatísticos: coeficiente de determinação (R^2), erro absoluto médio (MAE), erro quadrático médio (MSE), raiz do erro quadrático médio (RMSE), critério de informação de Akaike (AIC) e critério de informação bayesiano (BIC).

Também foi realizada uma avaliação da capacidade preditiva dos modelos. Nesse procedimento, os modelos foram ajustados utilizando os dados anteriores ao Ano 12, e as previsões geradas foram comparadas com os valores efetivamente observados nesse período. Como referência, foi utilizado um modelo ingênuo, que simplesmente repete o último valor disponível.

No ajuste dentro da amostra, o modelo linear apresentou MAE de aproximadamente 0,500 bilhão e RMSE de 0,664 bilhão. Entretanto, ao prever os valores do Ano 12, o MAE

aumentou para 2,300 bilhões, enquanto o modelo de referência apresentou MAE de 2,239 bilhões.

Essa diferença mostra que, apesar de apresentar um ajuste satisfatório aos dados históricos, o modelo linear possui limitações para representar as mudanças observadas no último período.

3.7. Comparação entre três modelos

Além da regressão linear, foram avaliados outros dois modelos: o quadrático, que permite representar mudanças na velocidade de crescimento da receita, e o modelo com indicadores específicos para cada ano.

Os resultados mostraram que os modelos mais flexíveis conseguiram representar melhor os dados observados. Entretanto, um ajuste mais preciso dentro da amostra não significa, necessariamente, que o modelo terá melhor desempenho ao prever valores futuros.

Os valores de R^2 within encontrados foram de 0,840 para o modelo linear, 0,963 para o quadrático e 0,996 para o modelo com efeitos específicos por ano.

Na previsão do Ano 12, o modelo quadrático apresentou MAE de aproximadamente 1,347 bilhão, resultado inferior ao erro registrado pelo modelo linear. Já o modelo com indicadores anuais, embora tenha apresentado o maior R^2 within, não permite realizar diretamente previsões para períodos que ainda não foram observados.

3.8. Diagnóstico dos resíduos

A análise dos resíduos foi realizada por meio de gráficos e testes estatísticos, incluindo os testes de Breusch-Pagan e Jarque-Bera.

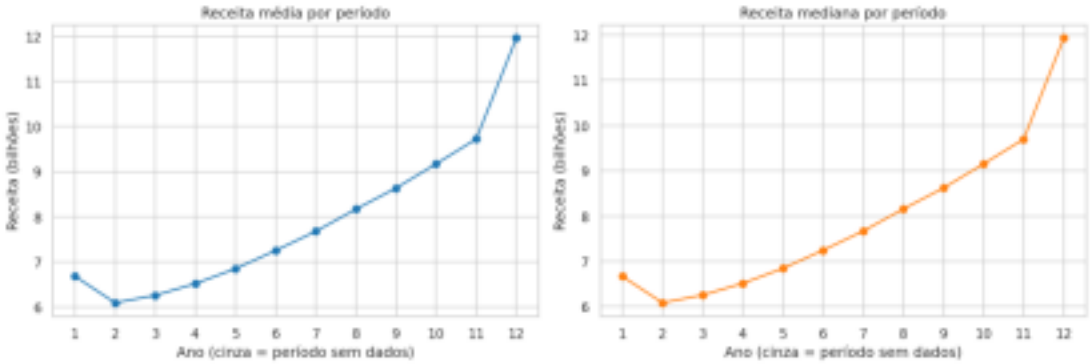
Os resultados indicaram diferenças na dispersão dos erros entre os períodos, desvios em relação à distribuição normal e correlação entre resíduos pertencentes ao mesmo cenário em anos distintos.

Diante dessas características, a utilização de erros-padrão agrupados por cenário contribui para tornar a inferência estatística mais adequada. No entanto, essa medida não elimina as limitações relacionadas à forma funcional escolhida para representar o comportamento dos dados.

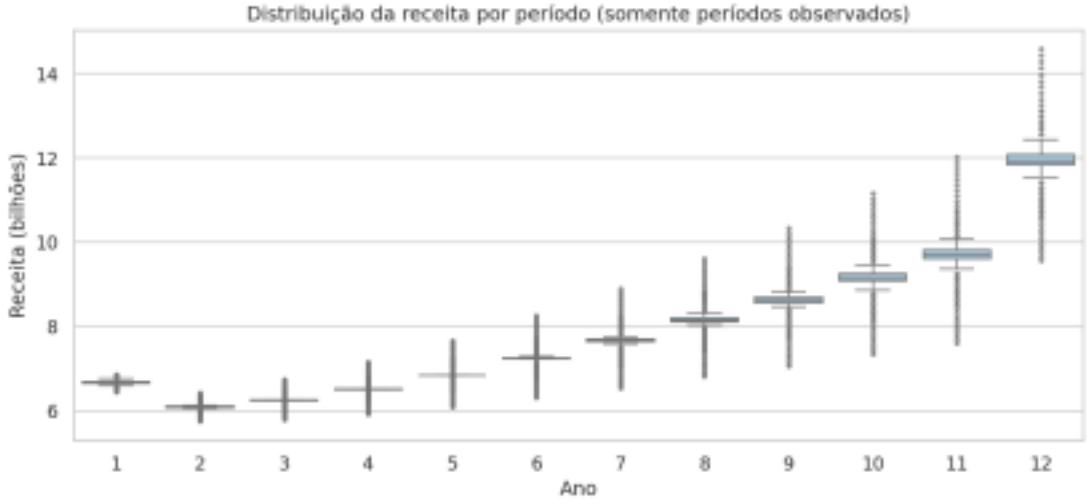
4. Gráficos

Os gráficos elaborados permitem visualizar a evolução da receita ao longo do tempo, comparar os valores observados com aqueles estimados pelos modelos e analisar o comportamento dos resíduos. Todas as visualizações foram produzidas a partir dos dados tratados no notebook.

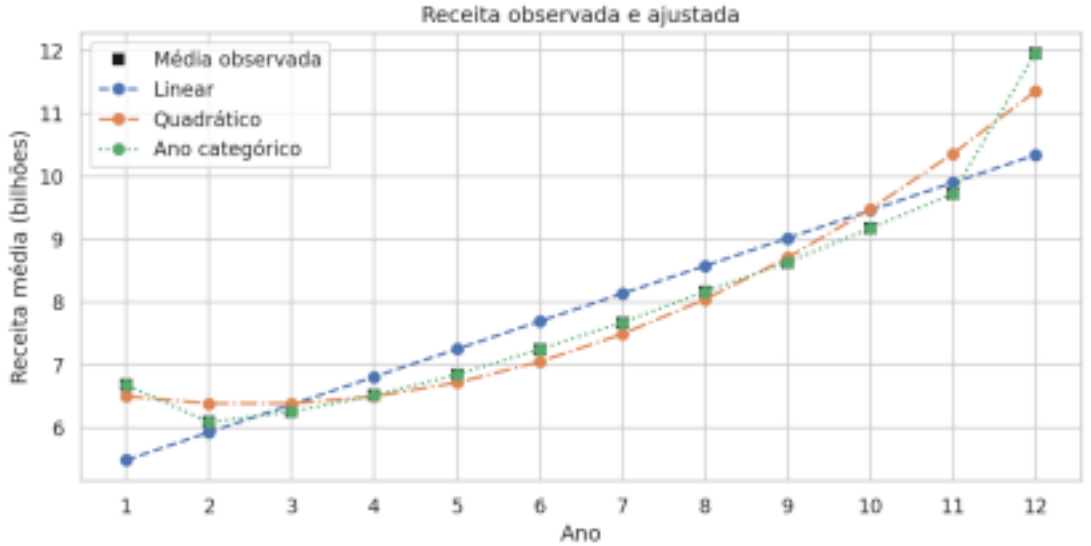
1. Receita média e mediana por período: os dois gráficos mostram como as principais medidas de tendência central evoluíram entre o Ano 1 e o Ano 12.



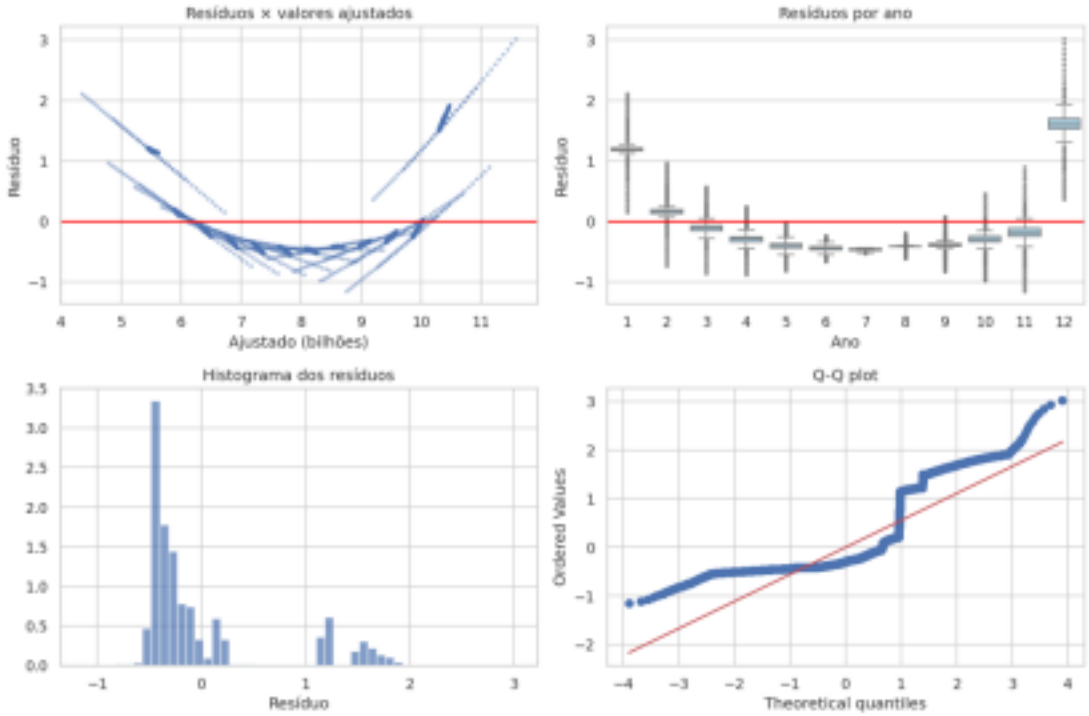
2. Boxplot da receita por período: permite comparar as medianas, a dispersão dos dados e a presença de valores extremos em cada período.



3. Valores observados e ajustados pelos modelos: apresenta a comparação entre os valores reais e as estimativas dos modelos, destacando os períodos em que a regressão linear apresenta maiores diferenças e como os modelos quadrático e com efeitos específicos por ano se comportam.



4. Resíduos em função dos valores ajustados: permite observar possíveis mudanças na dispersão dos erros conforme os valores estimados de receita aumentam ou diminuem.



5. Discussão dos resultados

Os resultados obtidos mostram que a receita apresentou crescimento ao longo dos 12 períodos analisados, embora esse aumento não tenha ocorrido de forma constante. A média passou de aproximadamente 6,679 bilhões no primeiro período para 11,962 bilhões no último. Os gráficos também deixam claro que, apesar da tendência positiva, os aumentos não tiveram a mesma intensidade em todos os anos.

A regressão linear com efeitos fixos confirmou a existência de uma tendência positiva estatisticamente significativa. Entretanto, como esse modelo representa a evolução da receita por meio de uma única reta, ele não consegue acompanhar completamente as mudanças que ocorreram ao longo do tempo. Os valores mais elevados de R^2 within obtidos pelos modelos quadrático e com efeitos específicos por ano indicam que a trajetória da receita apresenta um comportamento mais complexo, com alterações na taxa de crescimento.

Essa limitação também ficou evidente na avaliação das previsões. Ao utilizar apenas os dados anteriores para estimar a receita do Ano 12, o modelo linear apresentou um erro considerável. O modelo quadrático conseguiu um resultado melhor, mas também não reproduziu completamente a variação observada. Isso demonstra que um modelo pode apresentar um bom ajuste aos dados históricos e, ainda assim, não alcançar a mesma precisão ao prever novos períodos.

Na comparação dos erros absolutos médios de previsão, o modelo linear registrou MAE de 2,300 bilhões, enquanto o modelo de referência, que utiliza o último valor conhecido como previsão, apresentou 2,239 bilhões. O modelo quadrático, por sua vez, reduziu esse erro para 1,347 bilhão, sendo a alternativa com melhor desempenho entre os modelos avaliados que permitem prever o período seguinte.

A avaliação dos resíduos também revelou limitações importantes. Foram identificadas

violações de pressupostos comuns da regressão, especialmente em relação à homogeneidade da variância e à normalidade dos erros. O agrupamento dos erros-padrão por cenário ajuda a tornar a inferência mais robusta diante da dependência entre observações de uma mesma unidade, mas não resolve, por si só, as dificuldades do modelo linear em representar toda a trajetória da receita.

Outro ponto importante está relacionado às características da própria base de dados. Embora todos os cenários possuam registros para os 12 períodos, os valores não foram corrigidos pela inflação e os períodos não estão associados a anos específicos do calendário. Além disso, não existem informações suficientes para identificar se determinados cenários representam unidades relacionadas.

Por esse motivo, os resultados permitem identificar uma associação estatística entre o período e a receita, mas não são suficientes para afirmar que as mudanças observadas foram causadas diretamente pela passagem do tempo.

Assim, a interpretação dos resultados deve considerar tanto os indicadores estatísticos quanto os gráficos e as limitações dos dados, evitando conclusões que ultrapassem o que a análise permite demonstrar.

6. Conclusão

A análise realizada permite concluir que a receita apresentou uma tendência média de crescimento ao longo dos 12 períodos, com significância estatística ao nível de 5%. Apesar disso, o aumento não ocorreu de forma constante, apresentando variações ao longo do tempo.

A regressão linear com efeitos fixos mostrou-se adequada para identificar a existência dessa tendência média. Por outro lado, os modelos quadrático e com efeitos específicos por ano conseguiram representar melhor as mudanças observadas na receita. Na avaliação preditiva do último período, o modelo quadrático também apresentou um erro menor que o registrado pela regressão linear.

Para aprofundar o estudo, seria importante investigar a origem dos registros semelhantes entre cenários, confirmar a unidade monetária utilizada, relacionar os períodos a anos específicos do calendário, aplicar correção inflacionária aos valores e avaliar a capacidade preditiva dos modelos em diferentes intervalos de tempo. Essas etapas ajudariam a verificar se os resultados permanecem consistentes em outras condições de análise.

Também seria relevante investigar possíveis fatores econômicos e contábeis compartilhados entre os cenários, uma vez que a análise atual não permite identificar as causas específicas do crescimento observado.

7. Anexos

- Link do notebook