PROFESSOR: Rodnil da Silva Moreira Lisboa	
CURSO: Ciência da Computação	
DISCIPLINA: Análise Inferencial de Dados	
TURMA: Noturno	**DATA:** 09/11
ALUNO(A): Enzo Henrique, Harry Zhu, Murilo Ângelo, Vitor Kolle	

1. Introdução

Este trabalho apresenta uma análise dos dados financeiros disponibilizados pela CTI, com o propósito de examinar a evolução da receita dos cenários ao longo dos períodos observados. Entre as contas do balanço patrimonial (BAL), da demonstração do resultado do exercício (DRE) e do fluxo de caixa (FLU), selecionou-se a conta DRE - Receita, por permitir a avaliação direta da variação dos valores registrados.

A investigação ultrapassa a análise descritiva, buscando identificar a existência de uma tendência de crescimento ou redução da receita e verificar sua significância estatística. Para isso, foram realizados procedimentos de organização e tratamento dos dados, cálculo de estatísticas por período, elaboração de visualizações e comparação de modelos de regressão.

Foram estabelecidas duas hipóteses: a hipótese nula (H0), segundo a qual não existe tendência média da receita ao longo do tempo, e a hipótese alternativa (H1), que pressupõe a existência dessa tendência. Adotou-se um nível de significância de 5%, considerando valores-p inferiores a 0,05 como evidência estatística para rejeição de H0.

A versão da base de dados empregada contempla 12 períodos consecutivos, identificados do Ano 1 ao Ano 12.

2. Metodologia

A análise foi desenvolvida no ambiente Google Colab, utilizando a linguagem Python e as bibliotecas pandas, NumPy, SciPy, Matplotlib e Seaborn. O procedimento metodológico compreendeu a importação e limpeza dos dados, a verificação de sua estrutura, a análise exploratória da receita, o ajuste de modelos estatísticos e a avaliação dos resíduos e dos erros de previsão.

Considerando que cada cenário possui observações em diferentes períodos, adotou-se um modelo de regressão com efeitos fixos por cenário. Essa abordagem permite controlar diferenças invariantes no tempo entre os cenários e estimar a variação da receita dentro de cada unidade de análise. Adicionalmente, foram utilizados erros-padrão agrupados por cenário, a fim de considerar a possível dependência entre observações de uma mesma unidade em períodos distintos.

Determinados procedimentos estatísticos foram implementados diretamente com NumPy e SciPy, incluindo a centralização das variáveis em relação às médias de cada cenário e a aplicação de testes aos resíduos. Os valores monetários foram expressos em bilhões, sem correção inflacionária.

Para estimar o modelo de efeitos fixos, aplicou-se a transformação within, que consiste em subtrair de cada observação a média correspondente ao seu cenário. Esse procedimento permite isolar a variação temporal interna aos cenários, eliminando do ajuste as diferenças constantes entre eles.

3. Desenvolvimento e Resultados

1. **Identificação da base de dados e configuração de preferências**

Inicialmente, foram importadas as bibliotecas necessárias, definido o nível de significância de 5% e estabelecida uma semente aleatória para favorecer a reprodutibilidade. Como o arquivo CSV não apresenta cabeçalho e utiliza ponto e vírgula como delimitador, os campos foram inicialmente lidos como texto, com posterior conversão dos valores numéricos registrados no formato brasileiro.

2. **Tratamento e organização dos dados**

Na etapa de pré-processamento, foram padronizadas as denominações das contas, extraídos os identificadores numéricos dos períodos e convertida a coluna de valores para o tipo numérico. Também foram verificadas ocorrências de dados ausentes e registros duplicados. Para a conta DRE - Receita, não foram identificados valores ausentes, duplicações de um mesmo cenário e ano ou receitas menores ou iguais a zero.

Após a filtragem da conta selecionada, a amostra resultante apresentou 14.400 observações, referentes a 1.200 cenários acompanhados durante 12 períodos.

3. **Estrutura do painel de dados**

A base contém uma observação de receita para cada combinação de cenário e período, caracterizando um painel balanceado de 12 anos. Dessa forma, não foi necessário imputar valores ausentes nem gerar observações artificiais.

Essa estrutura possibilita examinar a trajetória temporal de cada cenário durante todo o intervalo analisado. Entretanto, permanece necessária a consideração de eventuais características compartilhadas entre diferentes unidades.

4. **Análise exploratória por período**

Para cada período, foram calculados o número de observações, a média, a mediana, o desvio-padrão, os valores mínimo e máximo e o coeficiente de assimetria. As representações gráficas indicaram uma trajetória geral de crescimento, embora com variações na intensidade entre os períodos. Também foram identificados valores coincidentes em determinados cenários, aspecto que requer cautela, pois a documentação da base não esclarece possíveis relações entre essas unidades.

A receita média passou de aproximadamente 6,679 bilhões no Ano 1 para 11,962 bilhões no Ano 12. Ressalta-se que os valores são nominais e que a moeda de referência não é explicitamente informada no arquivo.

5. **Regressão linear com efeitos fixos**

O primeiro modelo consistiu em uma regressão linear da receita em função do período, com efeitos fixos por cenário. O coeficiente associado ao tempo foi positivo e apresentou valor-p inferior a 0,05, permitindo rejeitar H0 e identificar evidências de uma tendência média crescente. Esse resultado, contudo, não implica crescimento uniforme ao longo dos períodos.

O coeficiente estimado foi de aproximadamente 0,4413 bilhão por período. O coeficiente de determinação within (R^2 within) foi de 0,840, indicando que o modelo linear explica parcela expressiva, mas não integral, da variação temporal da receita dentro dos cenários.

6. **Qualidade do ajuste e previsão**

A qualidade dos ajustes foi avaliada por meio dos indicadores R^2, erro absoluto médio (MAE), erro quadrático médio (MSE), raiz do erro quadrático médio (RMSE), critério de informação de Akaike (AIC) e critério de informação bayesiano (BIC). Também foi realizada uma avaliação preditiva: os modelos foram ajustados com os períodos anteriores ao Ano 12, e suas previsões foram comparadas com os valores observados nesse último período. Como referência, utilizou-se um modelo ingênuo que repete o último valor disponível.

No ajuste dentro da amostra, o modelo linear apresentou MAE de aproximadamente 0,500 bilhão e RMSE de 0,664 bilhão. Na previsão do Ano 12, o MAE atingiu 2,300 bilhões, enquanto o modelo de referência apresentou MAE de 2,239 bilhões. Esse resultado evidencia a limitação da especificação linear para representar a variação observada no último período.

7. **Comparação entre três modelos**

Além do modelo linear, foram estimados um modelo quadrático, capaz de representar mudanças na taxa de crescimento ao longo do tempo, e um modelo com indicadores específicos para cada ano. Os testes comparativos indicaram melhor ajuste dos modelos mais flexíveis aos dados observados. Entretanto, maior capacidade de ajuste

dentro da amostra não implica necessariamente melhor desempenho preditivo fora dela.

Os valores de R^2 within foram de 0,840 para o modelo linear, 0,963 para o quadrático e 0,996 para o modelo com efeitos específicos por ano. Na previsão do Ano 12, o modelo quadrático apresentou MAE de aproximadamente 1,347 bilhão, inferior ao obtido pelo modelo linear. O modelo com indicadores anuais, por sua vez, não permite extrapolação direta para um período ainda não observado.

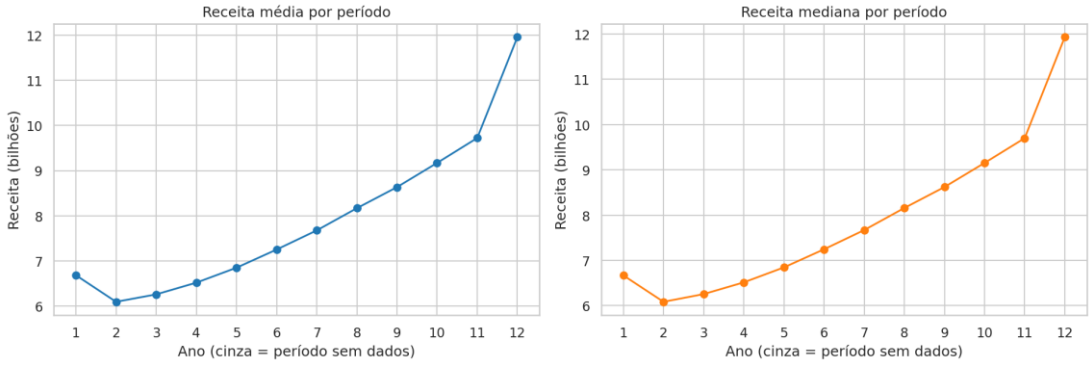
8. **Diagnóstico dos resíduos**

A análise dos resíduos foi realizada por meio de visualizações e testes estatísticos, incluindo os testes de Breusch-Pagan e Jarque-Bera. Os resultados apontaram heterogeneidade na dispersão dos erros entre períodos, desvios em relação à distribuição normal e correlação entre resíduos de um mesmo cenário em anos distintos. Assim, a utilização de erros-padrão agrupados por cenário contribui para uma inferência mais adequada, embora não elimine limitações decorrentes da especificação funcional do modelo.

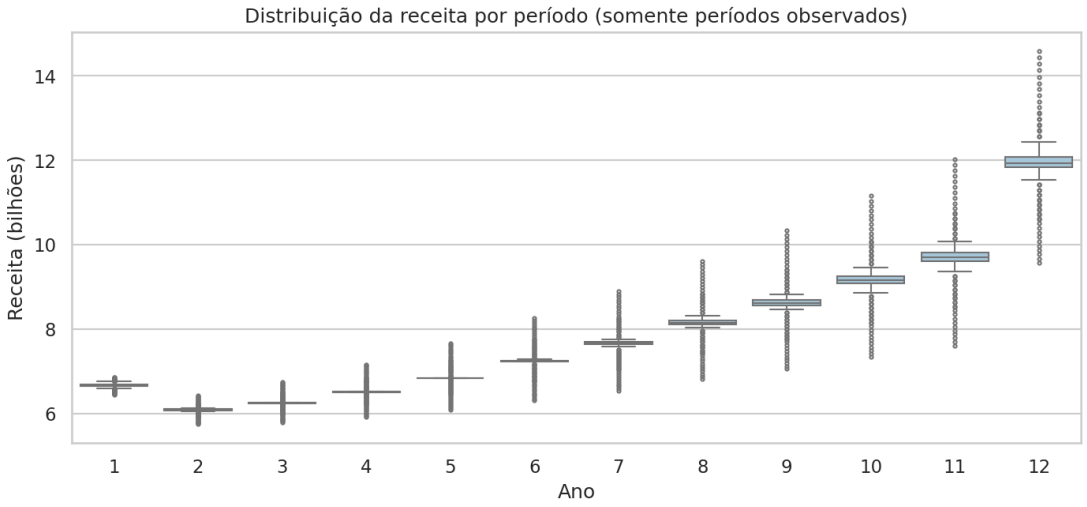
4. Gráficos

As visualizações a seguir permitem examinar a evolução temporal da receita, comparar os valores observados e estimados pelos modelos e avaliar o comportamento dos resíduos. Todos os gráficos foram produzidos com base nos dados processados no notebook.

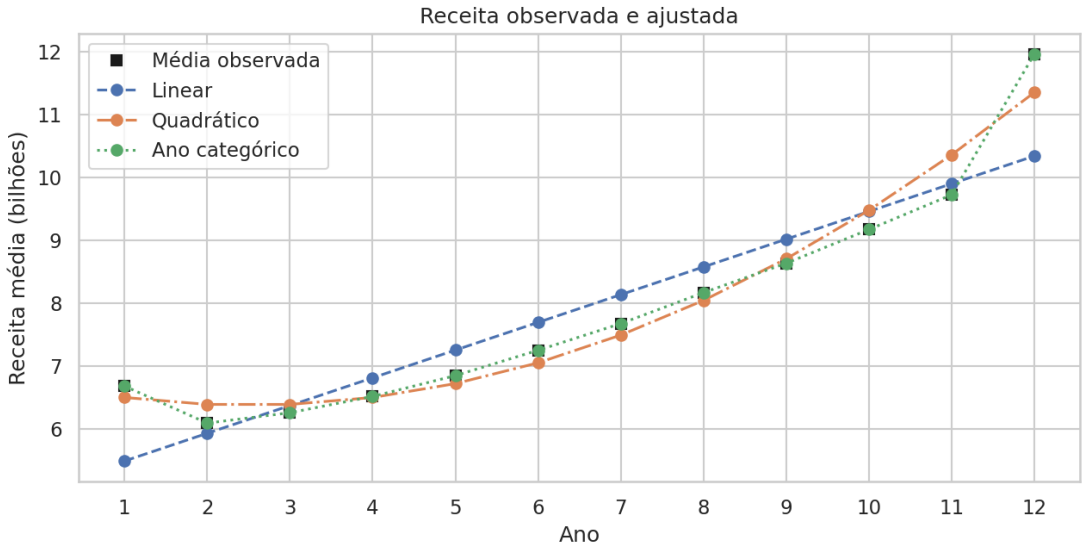
1. Receita média e mediana por período. Os dois painéis apresentam a evolução das medidas de tendência central entre o Ano 1 e o Ano 12.



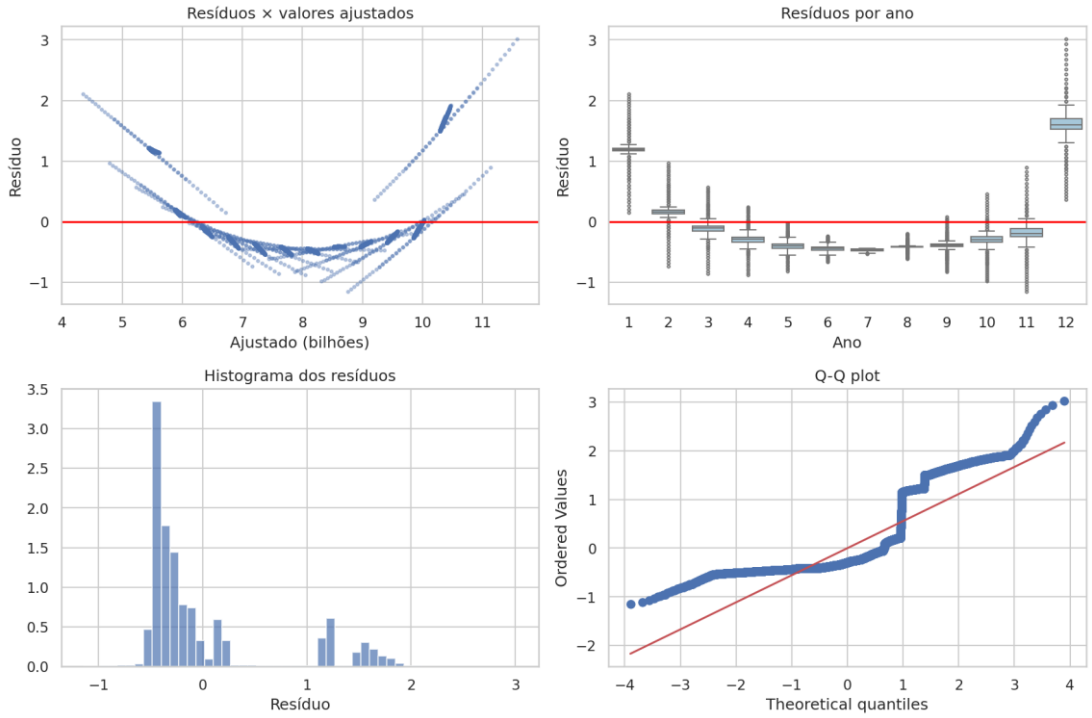
2. Boxplot da receita por período. A visualização permite comparar medianas, dispersão e valores extremos da receita entre os períodos.



3. Valores observados e ajustados pelos modelos. A comparação evidencia os períodos em que a regressão linear apresenta maiores desvios e o comportamento dos ajustes quadrático e com efeitos específicos por ano.



4. Resíduos em função dos valores ajustados. O gráfico permite verificar possíveis alterações na dispersão dos erros conforme o nível estimado de receita.
5. Resíduos por ano. A distribuição temporal dos resíduos auxilia na identificação de períodos em que o modelo linear superestima ou subestima a receita.
6. Histograma dos resíduos e gráfico Q-Q. Essas representações permitem avaliar a proximidade dos resíduos em relação à distribuição normal e identificar desvios, especialmente nas caudas.



5. Discussão dos resultados

A análise conjunta dos resultados indica crescimento da receita ao longo dos 12 períodos, embora em ritmo não uniforme. A média aumentou de aproximadamente 6,679 bilhões no primeiro período para 11,962 bilhões no último. As visualizações reforçam que uma tendência geral positiva não corresponde necessariamente a incrementos de mesma magnitude em todos os anos.

A regressão linear com efeitos fixos identificou uma tendência positiva estatisticamente significativa. Entretanto, por representar a evolução temporal por uma única reta, esse modelo não captura integralmente as mudanças observadas na trajetória. Os valores superiores de R^2 within dos modelos quadrático e com efeitos específicos por ano sugerem uma dinâmica temporal mais complexa, caracterizada por alterações na taxa de crescimento.

A avaliação preditiva evidenciou essa limitação. Ao estimar a receita do Ano 12 utilizando somente os períodos anteriores, o modelo linear apresentou erro elevado. O modelo quadrático obteve desempenho superior, embora também não tenha reproduzido integralmente a variação observada. Portanto, a qualidade do ajuste aos dados históricos não garante precisão na previsão de novos períodos.

Na comparação dos erros absolutos médios de previsão, o modelo linear registrou MAE de 2,300 bilhões, enquanto o modelo de referência, baseado na repetição do último valor conhecido, apresentou 2,239 bilhões. O modelo quadrático reduziu esse indicador para 1,347 bilhão, constituindo a alternativa com melhor desempenho entre os modelos avaliados que permitem previsão do período seguinte.

Os diagnósticos dos resíduos também evidenciaram violações de pressupostos usuais da regressão, particularmente quanto à homogeneidade da variância e à normalidade dos erros. O agrupamento dos erros-padrão por cenário torna a inferência mais robusta à dependência intragrupo, mas não corrige, isoladamente, a inadequação da forma linear para representar toda a trajetória.

A interpretação dos resultados também deve considerar as limitações da base. Embora todos os cenários apresentem registros para os 12 períodos, os valores não foram ajustados pela inflação, e os períodos não estão vinculados a anos de calendário. Além disso, não há informação suficiente para determinar se alguns cenários correspondem a unidades relacionadas. Desse modo, os resultados demonstram associação estatística entre período e receita, sem permitir atribuir causalidade às variações identificadas.

Por conseguinte, a interpretação dos achados deve integrar os indicadores quantitativos, as representações gráficas e as restrições dos dados antes da formulação de conclusões mais abrangentes.

6. Conclusão

Os resultados permitem concluir que existe uma tendência média positiva da receita ao longo dos 12 períodos, estatisticamente significativa ao nível de 5%. Entretanto, a evolução não ocorreu de maneira constante. A regressão linear com efeitos fixos foi adequada para investigar a existência de uma tendência média, enquanto os modelos quadrático e com efeitos específicos por ano apresentaram maior capacidade de representar as variações observadas. Na avaliação preditiva do último período, o modelo quadrático também registrou erro inferior ao do modelo linear.

Como possibilidades de aprofundamento, recomenda-se investigar a origem dos registros semelhantes entre cenários, confirmar a unidade monetária, associar os períodos a anos de calendário, corrigir os valores pela inflação e avaliar o desempenho preditivo em diferentes intervalos temporais. Essas medidas permitiriam examinar a estabilidade dos resultados em outras condições de análise.

Adicionalmente, recomenda-se investigar fatores econômicos e contábeis potencialmente comuns a diferentes cenários, uma vez que a análise desenvolvida não permite identificar causas específicas para o crescimento observado.

7. Anexos

- Link do notebook